경량 AI 기반 Edge-BMS: 클라우드 의존도 감소와 실시간 셀 제어를 위한 딥러닝 적용 연구

<국문초록>

본 연구는 클라우드 의존도를 줄이고 실시간 셀 제어가 가능한 경량 AI 기반 엣지 배터리 관리 시스템(Edge-BMS)을 구현하는 것을 목표로 한다. 시계열 입력 데이터(전류, 전압, 온도)를 기반으로 배터리 충전 상태 (State of Charge, SoC)를 예측하기 위해 GRU+MLP, LSTM, Conv1D+MLP 세 가지 딥러닝 모델을 비교하였으며, 각 모델은 파라미터 수를 최소화하는 경량화 구조로 설계되었다. STM32 기반 ST NUCLEO-G431RB 보드에 실제 탑재 가능한 모델은 Conv1D+MLP였으며, 이 모델은 경량화 이후에도 높은 예측 성능을 유지하였다. 본 모델은 삼성 INR18650-35E 배터리 4셀을 대상으로 한 셀 밸런싱 실험에 활용될 예정이며, 본 논문에서는 SoC 예측 모델 개발과 엣지 디바이스 실현 가능성에 초점을 맞추었다.

김 수 연, 노 이 현, 장 용 준

I. 서론

지속가능한 에너지 시스템에 대한 관심이 전 세계적으로 높아지면서 전기차(EV), 에너지 저장 시스템(ESS), 휴대용 전자기기 등에 활용되는 리튬이온 배터리의 역할은 날로 중요해지고 있다. 특히 리튬이온 배터리는 높은 에너지 밀도, 우수한 수명 특성, 반복 충·방전에 대한 안정성 덕분에 다양한 산업 분야에서 핵심적인 에너지 저장 장치로 채택되고 있다. 이에 따라 배터리의 성능과 안전성을 효과적으로 관리하기 위한 배터리 관리 시스템(Battery Management System, BMS)의 기술적 고도화가 필수적으로 요구되고 있다.

BMS는 일반적으로 배터리 셀의 전압, 전류, 온도 등의 상태 정보를 실시간으로 수집하고 분석하여 과충전 및 과방전 방지, 셀 간 균형 조정(cell balancing), 잔존 용량 추정(State of Charge, SoC), 수명 예측(State of Health, SoH) 등을 수행한다. 이러한 기능은 배터리의 성능 유지를 넘어 시스템의 안전성과 에너지 효율을 좌우하는 핵심 기술로 작용한다. 최근에는 인공지능(AI) 기술이 발전함에 따라 BMS에 딥러닝, 머신러닝 기반의 예측 모델이 도입되어 SoC 및 SoH 예측 정확도를 향상시키는 연구가 활발히 이루어지고 있다. 하지만 대부분의 연구는 고성능 컴퓨팅 환경을 전제로 하거나 클라우드 연산 자원을 기반으로 하고 있으며, 실제 저전력 엣지 디바이스에서의 실시간 운용은 많이 다뤄지고 있지 않은 실정이다.

실제로 산업 현장이나 이동체 환경에서는 클라우드 기반 BMS의 연산 지연, 통신 불안정, 개인정보 보안 문제 등이 실시간 제어에 있어 제약으로 작용할 수 있다. 특히 전기차나 드론처럼 실시간 반응성과 자율성이 중요한 시스템에서는 중앙서버와의 통신 지연 없이 즉각적인 제어가 가능한 엣지 기반 BMS(Edge-BMS)의 필요성이 대두되고 있다. 엣지 BMS는 배터리 상태 데이터를 로컬 디바이스에서 실시간으로 처리하고 제어 신호를 생성함으로써, 네트워크 연결 유무와 관계없이 독립적으로 작동할 수 있는 구조를 제공한다. 그러나 엣지 디바이스는 연산 자원 및 저장 용량이 제한되어 있어, 전통적인 딥러닝 모델을 그대로 적용하기에는 현실적인 한계가 존재한다. 따라서 경량화된 AI 모델을 설계하고 이를 엣지 디바이스에 적합하게 최적화하는 연구가 필요하다.

본 연구에서는 클라우드 의존도를 낮추면서도 실시간 셀 제어가 가능한 경량 AI 기반의 Edge-BMS 구조를 제안하고, 이를 실제 저전력 마이크로컨트롤러(MCU) 보드인 ST NUCLEO-G431RB(STM32)에 적용하여 구현 가능성을 실증하고자 한다. 이를 위해 배터리의 전류, 전압, 온도 데이터를 시계열 입력으로 활용하여 SoC를 예측하는 딥러닝 모델을 설계하였고, 다양한 모델 구조 중에서 MCU 환경에 적합한 최적의 모델을 선정하는 비교 실험을 진행하였다. 비교 대상 모델은 GRU(Gated Recurrent Unit)+MLP(Multi-Layer Perceptron), LSTM(Long Short-Term Memory), Conv1D+MLP의 세 가지 구조로, 이들 모두 시계열 패턴을 학습하기 위한 구조적 장점을 갖고 있으며, 예측 성능과 경량화 가능성에 따라 엣지 디바이스 탑재 적합성이 평가되었다.

모든 모델은 TensorFlow 프레임워크를 기반으로 설계되었으며, 모델 경량화를 위해 전체 파라미터 수 제한과 모델 깊이 최소화 전략을 적용하였다. 그 결과, GRU와 LSTM 모델은

경량화 이후에도 모델 파라미터 수와 메모리 요구량이 STM32 MCU의 제한을 초과하여 실질적인 탑재가 불가능하였으며, Conv1D+MLP 모델만이 보드 탑재가 가능함과 동시에 우수한 SoC 예측 성능을 유지하는 것으로 나타났다. 본 논문에서는 Conv1D+MLP 모델의 구조와 성능 분석 결과를 중심으로 기술하며, 이를 실제 STM32 보드에 탑재하여 엣지 디바이스에서 SoC 예측이 어떻게 수행되는지를 실험적으로 확인하였다. 아울러 해당 예측 모델은 삼성 INR18650-35E 리튬이온 배터리 셀 4개를 이용한 셀 밸런싱 실험에 적용할 예정이나, 본 논문에서는 모델 구현과 엣지 실행 환경에 집중하였고 추후 밸런싱 결과 분석을 진행할 예정이다.

본 연구는 경량화된 AI 기반 SoC 예측 모델이 저전력 MCU에서 실시간으로 운용 가능함을 보이며, 향후 클라우드와의 의존도를 낮추고 다양한 실시간 응용 시스템에서 독립적으로 동작할 수 있는 Edge-BMS 구현에 기여할 수 있을 것으로 기대된다.

II. 본론

2.1 기존 연구

리튬이온 배터리의 상태 추정(State of Charge, SoC 및 State of Health, SoH)은 BMS 분야의 핵심 연구 주제로 지속적으로 발전되어 왔다. 초기에는 전통적인 전기화학 모델이나 경험적 회귀 기법이 주를 이루었으나, 최근에는 대량 시계열 데이터를 효과적으로 해석할 수 있는 인공지능(AI) 기반 접근법이 대두되고 있다. 그럼에도 불구하고, 기존 연구는 고성능 컴퓨팅 환경 혹은 클라우드 연산 자원에 기반하거나, AI 모델 경량화 혹은 임베디드 현장 적용 가능성 측면에서는 한계가 뚜렷하게 나타난다.

기존 BMS는 일반적으로 등가회로모델(Equivalent Circuit Model) 또는 전기화학 모델에 Kalman Filter, Particle Filter와 같은 상태추정 기법을 결합하여 SoC/SoH를 추정해왔다[1]. 이 방식은 실시간 동작과 구현이 용이하다는 장점이 있으나, 배터리의 비선형적 열화 특성이나 다양한 운용 환경에서의 적응성이 부족해 실제 산업현장 적용 시 오차 누적이나 비효율적인 제어로 이어질 수 있다.

최근에는 머신러닝 및 딥러닝 기반 예측 모델이 활발히 도입되고 있다. 전통적인 머신러닝 접근법으로는 다항회귀, 서포트 벡터 회귀(SVR), 랜덤 포레스트(Random Forest) 등 다양한 기법이 활용되며, 일부 연구에서는 SVR 모델 등 비교적 단순하고 경량적인 구조만으로 딥러닝 수준의 예측 정확도를 달성하기도 한다[2][3]. 하지만 이들 모델의 한계는 온도, 전류, 전압 등 시계열 데이터의 복잡한 패턴이나 긴 주기의 열화 경향을 충분히 반영하지 못한다는 점이며, 실제 임베디드 환경에서의 확장성은 제한적이라는 비판이 제기된다.

딥러닝 분야에서는 LSTM, GRU 등 RNN 계열 모델이 배터리 데이터의 시계열성, 장기 의존성 분석에 특화되어 SoH 예측 정확도를 크게 향상시켰다[4]. CNN

기반(Model: 1D-CNN 등) 모델 역시 DC/DC Converter, 대용량 데이터셋 환경에서 노이즈 억제 및 특징 압축에 장점을 보여 소형화된 네트워크 연구가 진행됐다[1]. 하지만 대부분 연구가 고성능 서버, 클라우드 환경에서 모델을 학습시키거나 대용량 메모리를 활용하는 구조이며, 실제 모델 파라미터 수가 많아 MCU 등 메모리/연산 자원이 부족한 현장 디바이스에서는 실시간 동작에 제약이 있다.

배터리 예지보전(BMS) 분야에서 모델 경량화만을 강조한 본격적 연구도 시작되고 있다. 예컨대 CNN 구조(Conv1D 기반 등)를 STM32Cube.AI 등 MCU 최적화 프레임워크를 통해 임베디드 장치에 실장하는 연구의 경우, 실제 SoH 또는 SoC 예측이 가능하나, 주로 단일 특성 또는 단순 패턴 감지에 한정되어, 복잡한 장기 열화 추세 및 멀티모달 데이터 적용에는 한계가 보고됐다[1][5].

또한, 최근 Adaptive Extended Kalman Filter(AEKF)나 확장 칼만필터 기반 경량 추정기가 STM32 MCU에 직접 구현된 사례도 있으나, 주요 내용은 등가회로 기반의 SoC 추정에 국한되어 딥러닝의 비선형 패턴 학습력 또는 다중 변수 기반 SoH/SoC 동시 추정 등 실질적 AI의 장점을 직접적으로 반영하지 못한다[6].

2.2 본 연구의 차별점

본 연구는 단순히 임베디드 활용을 위해 모델 파라미터만 줄인 것이 아니라, 실제 MCU(SRAM/FLASH 제한)에서 실시간으로 동작 가능한 딥러닝 구조(Conv1D+MLP)를 직접 비교・분석하여 최적의 운용 전략을 제시한다는 데 의의가 있다. 기존 LSTM, GRU, CNN 등 다양한 구조를 동일 환경(배터리 실제 시계열 데이터 및 STM32 타겟 보드)에서 분석, 경량화 과정을 거쳤음에도 GRU와 LSTM은 하드웨어 한계로 실 장착이 어려움을 직접 검증하였다. 반면, Conv1D+MLP 구조는 뛰어난 파라미터 효율성 및 연산 경제성을 바탕으로, 모델 경량화 후에도 SoC 예측 성능 저하 없이 안정적인 실시간 처리를 가능케 하는 점이 확인됐으며, 이와 같은 실제 탑재/운용 가능성을 중심으로 설계와 실험이 진행됐다.

특히, 본 연구는 데이터 전처리에서 시작하여 모델학습 및 임베디드 실시간 추론까지 전 과정을 아우르는 통합적 실험 및 분석결과를 제공함으로써, 기존의 예측 모델만 구축하거나 모델 경량화만 수행한 논문들과 실질적 차별성을 갖는다. 아울러, 제안 모델은 향후 셀 밸런싱 등 고도화된 배터리 제어 알고리즘과의 연계 및 표준화된 실시간 현장 적용에 유리한 확장성을 확보한다.

III. 실험 및 결과

1. SoC 예측 모델 설계 및 구현

1) 데이터셋 소개 및 전처리

사용된 데이터셋은 LG 18650HG2 Li-ion Battery에서 생성된 공개 시계열 데이터이다. 다양한 온도 조건, 충방전 속도, 하중 프로파일 하에서 수집되었다. 모든 입력 특성은 MinMaxScaler 기법을 사용하여 [0, 1] 범위로 정규화되었다. 이는 전류와 온도처럼 크기가 큰 특성들이 학습 과정에서 모델을 지배하는 것을 방지하기 위함이다.

2) 모델 구조 설명

본 연구에서는 배터리 충전 상태(State of Charge, SoC)를 예측하기 위한 경량 딥러닝 구조로서 Conv1D, GRU (Gated Recurrent Unit), LSTM (Long Short-Term Memory) 모델과 MLP(Multi-Layer Perceptron)를 통합하였다. 배터리의 충전 상태(State of Charge, SoC)는 전압, 전류, 온도 등 시계열 특성을 지닌 변수들에 따라 동적으로 변하는 복합적인 함수로 표현된다. 이러한 복잡성을 효과적으로 학습하기 위해 특성 추출부(Feature Extractor)와 회귀부(MLP Regressor)로 구성된 하이브리드 모델을 설계하였다.

특성 추출부에는 각각 Conv1D, GRU, 또는 단일층 LSTM 구조를 배치하였으며, 이는 입력 시계열 내에서 지역적 패턴 또는 장기 의존성을 학습하는 역할을 수행한다. 이후 공통적으로 연결되는 MLP 회귀부는 2~3단의 Fully Connected Layer로 구성되며, 전류-전압-온도 간의 비선형 관계를 고차원 공간에서 효과적으로 모델링하여 최종 SoC 값을 출력한다. 특히 MLP는 시간 정보를 직접 처리하지는 않지만, 앞선 시계열 계층에서 추출된 feature map을 기반으로 복잡한 회귀 문제에 대응할 수 있도록 설계되었다.

한편, 본 모델은 후처리 압축 기법을 사용하지는 않았으나, 모델 아키텍처 자체의 단순성과 파라미터 수 제한을 통해 경량 구조를 실현하였다. 세 가지 모델 모두 약 6만~8만 개 이내의 파라미터를 유지하며, 이는 Transformer 기반 모델이나 다층 RNN에 비해 현저히 낮은 연산량을 요구한다. 따라서 본 연구의 모델 구조는 소형화 및 실시간 운용 가능성을 동시에 고려한 경량 딥러닝 모델로 분류될 수 있다.

기존 연구에서는 단일 MLP 구조가 시간 순서를 반영하지 못하여 SoC 예측에 한계가 있음이 보고된 바 있으며[7], 이를 보완하기 위해 본 연구에서는 시계열 기반 Conv1D 또는 GRU 계층을 전처리부로 통합하여, 시간적 특성과 정적 회귀 능력을 결합한 하이브리드 구조를 도입하였다.

2-1. Conv1D-MLP

CNN(Convolutional Neural Network)은 시간 축을 따라 존재하는 국소적 패턴을 효율적으로 추출할 수 있어, 시계열 데이터 처리에서도 널리 활용되고 있다. 본 모델은 32 및 64개의 필터를 갖는 두 개의 1차원 합성곱 계층(Conv1D)을 통해 입력 시퀀스에서 특징을 계층적으로 추출하고, 이후 GlobalAveragePooling1D 계층을 통해 시간 축 정보를 압축하였다. 이 후단에는 256→128→64 유닛으로 구성된 MLP 회귀 계층이 연결되며, 최종적으로 SoC 값을 추정한다. Conv1D 구조는 병렬 처리가 가능하여 추론 속도에서 유리하며, 비교적 단순한 연산 구조로도 충분한 표현력을 확보할 수 있다는 점에서 엣지 디바이스와 같은 경량 AI 환경에 적합하다.

2-2. GRU-MLP

GRU(Gated Recurrent Unit)는 순환 신경망(RNN)의 일종으로, 시계열 입력의 시간적 의존 관계를 학습하는 데 적합한 구조이다. 본 연구에서는 시계열 전반의 장기 패턴을 요약할 수 있는 GRU 계층을 전처리 단계로 활용하고, 후속 회귀 예측을 위해 MLP(Dense) 계층과 결합한 GRU-MLP 하이브리드 구조를 구성하였다. 하이브리드 모델은 입력 시퀀스를 GRU 계층을 통해 64차원 벡터로 압축한 뒤, 256→128→64 유닛으로 구성된 완전연결층을 거쳐 SoC를 예측하는 방식이다. GRU는 상대적으로 적은 수의 파라미터로도 장기 상태 정보를 보존할 수 있어 자원 효율성이 높으며, 학습이 안정적인 장점을 가진다. 그러나 순차적 연산 특성으로 인해 추론 속도 측면에서는 병렬화가 가능한 합성곱 계열 모델에 비해 상대적인 제약이 존재할 수 있다.

2-3. LSTM

LSTM(Long Short-Term Memory) 구조는 GRU와 마찬가지로 RNN 계열에 속하며, 입시계열 데이터 내에서 장기 의존성(Long-term dependency)을 효과적으로 학습할 수 있도록 설계된 모델이다. 본 연구에서는 과도한 복잡도를 방지하고 연산 효율성을 확보하기 위해, 단일 LSTM 계층과 후속 MLP 회귀층(Dense 256→128→1)을 결합한 경량 구조를 채택하였다. 이러한 구성은 Chemali et al.(2017) 의 연구에서 제안된 바와 같이, 단일 LSTM 층만으로도 높은 SoC 예측 정확도를 달성할 수 있다[8]는 선행 결과를 바탕으로 하며, GRU 및 Conv1D 기반 모델과 파라미터 수를 유사하게 유지함으로써 구조적 공정성 또한 확보하였다.

2. SoC 예측을 위한 모델 성능 비교 및 결과 분석

1) 모델 성능 비교

세 모델은 동일한 입력 전처리 및 학습 조건(learning rate = 0.00001, optimizer = Adam, patience = 10)을 기반으로 학습되었으며, 테스트 셋에서의 예측 성능은 평균 제곱근 오차(RMSE), 평균 절대 오차(MAE), 평균 절대 백분율 오차(MAPE) 등의 지표를 활용하여 비교하였다.

<표 1> 모델 간 성능 비교

모델명	RMSE	MAE	MAPE (%)	MSE	Total Params
Conv1D-MLP	0.0375	0.0286	9.38	0.0014	64,385 (251.5 KB)
GRU-MLP	0.0536	0.0409	13.70	0.0030	71,105 (277.8 KB)
LSTM	0.0418	0.0294	9.53	0.0019	75,265 (294.0 KB)

Conv1D-MLP 모델이 RMSE 0.0375, MAE 0.0286, MAPE 9.38%로 가장 낮은 오차율을 기록하였으며, MSE 또한 0.0014로 우수한 성능을 나타냈다. 특히 전체 파라미터 수가 세 모델 중 가장 작아, 실시간 제어가 요구되는 Edge-BMS 시스템에 매우 적합한 경량 구조임을 확인할 수 있었다. Conv1D 구조는 지역적 시계열 특징을 효과적으로 추출할 수 있으며, 비교적 단순한 연산 구조 덕분에 추론 속도 또한 빠르다는 장점이 있다.

반면, GRU-MLP는 RMSE 0.0536, MAPE 13.70%로 가장 낮은 예측 성능을 보였으며, 파라미터 수 또한 7만 개 이상으로, 연산 효율성과 정확도 모두에서 열세를 보였다. 이는 시계열 패턴을 장기적으로 학습할 수 있는 구조임에도 불구하고, 짧은 사이클 기반의 비정형적 데이터에서는 GRU가 Conv1D만큼 효과적이지 않음을 시사한다.

LSTM 모델은 RMSE 0.0418, MAE 0.0294, MAPE 9.53%로 Conv1D 다음으로 우수한 성능을 보였지만, 전체 파라미터 수는 세 모델 중에서 가장 높았다. 이는 메모리 자원이 제한된 엣지 환경에서 운용 시 부담이 될 수 있으며, 추론 지연(latency) 측면에서도 상대적으로 불리한 구조로 판단된다.

2) 시계열 기반 SoC 추세 분석

<그림 1> Conv1D-MLP SoC 예측 모델

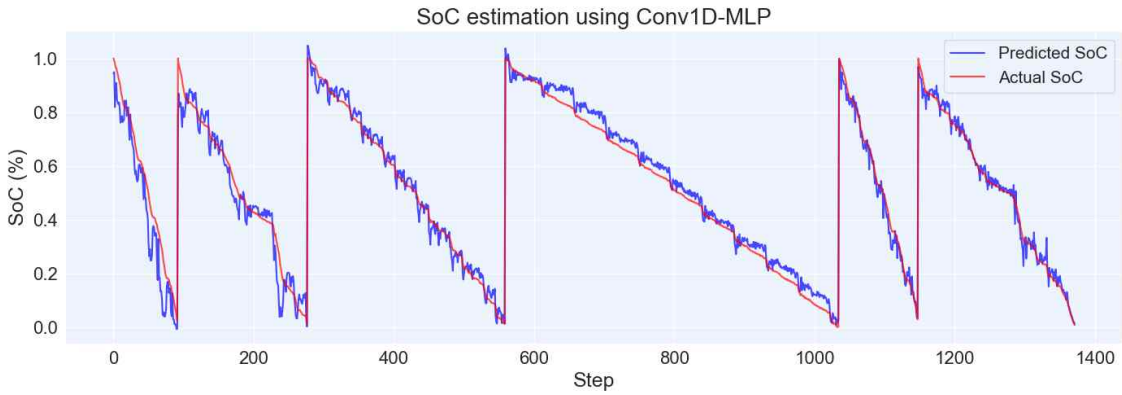

<그림 2> GRU-MLP SoC 예측 모델

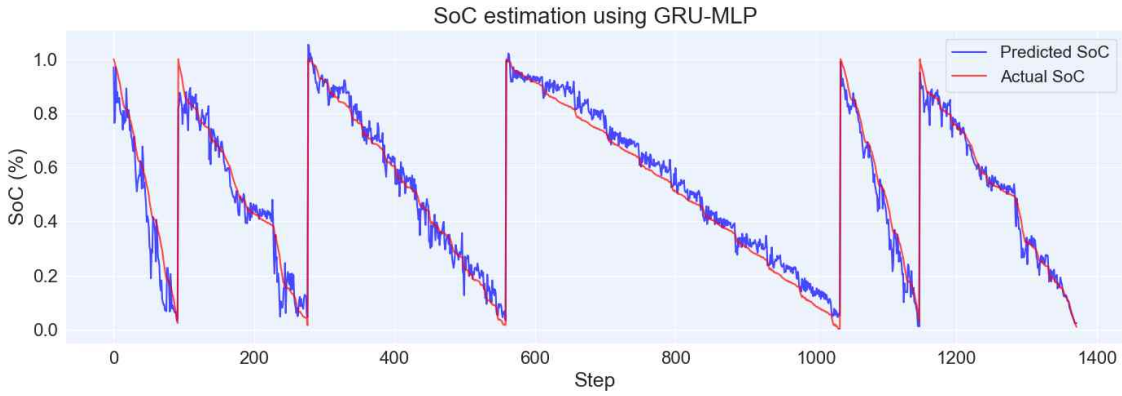

<그림 3> LSTM SoC 예측 모델

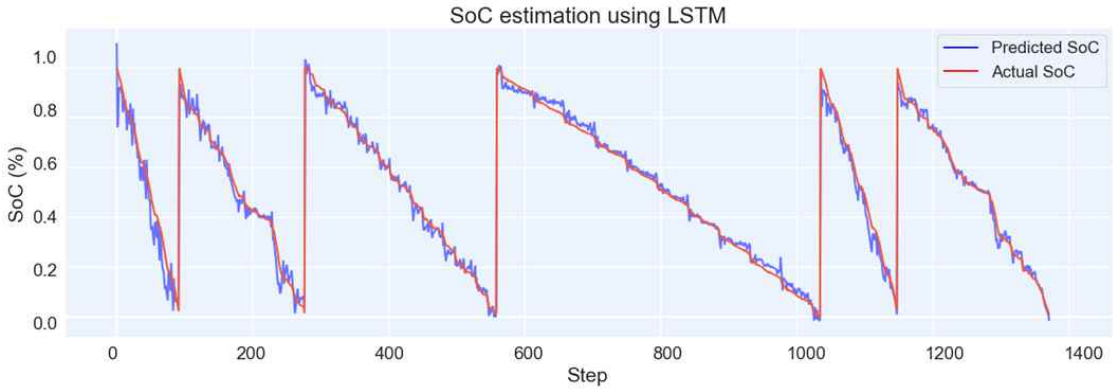

모델별 SoC 예측 결과를 시각화한 결과, 세 모델 모두 충·방전 구간의 전반적인 추세를 일정 수준 이상 재현하는 모습을 보였다. Conv1D-MLP 모델은 전반적으로 실제 SoC 곡선과 유사한 패턴을 보이지만, 일부 구간에서는 예측값이 실제 값의 급격한 변화에 반응하지 못해, 완만한 곡선 형태로 추정되는 경향도 관찰되었다.

GRU-MLP 모델은 시계열의 추세를 따르는 정확도 역시 제한적이었다. 특히 충전 또는 방전이 빠르게 이루어지는 구간에서는 예측 곡선이 실제 SoC의 변화를 정확히 따라가지 못하고 진동 또는 편향되는 경우가 빈번히 발생하였다. 이는 GRU 구조가 시계열 정보를 요약하는 과정에서 짧은 입력 시퀀스나 비정형 패턴에 민감하게 반응하는 특성에 기인한 것으로 해석된다.

LSTM 모델은 정량 지표에서 Conv1D보다는 다소 높은 오차를 보였지만, 시계열 흐름을 전반적으로 부드럽고 안정적으로 추정하는 특성이 있었다. 급격한 변화 구간에서도 실제 SoC의 형태를 비교적 자연스럽게 따라가는 양상이 확인되었으며, 이는 내부 상태(cell state)를 통한 장기 메모리 유지 기능 덕분으로 보인다. 그러나 LSTM은 전체 파라미터 수가 가장 많아, 연산 효율성과 실시간 처리 측면에서는 상대적으로 부담이 있을 수 있다.

따라서 본 연구에서는 정확성, 연산 효율성, 그리고 경량성 측면에서 최적의 균형을 갖춘 Conv1D-MLP 모델이 Edge-BMS 응용에 최적화된 구조임을 확인하였다. 이 모델은 배터리 잔존 용량의 실시간 추정이 요구되는 산업 환경에서도 충분히 적용 가능할 것으로 기대된다.

3. 셀 밸런싱 회로 설계 (Cell Balancing Circuit Design)

셀 밸런싱(cell balancing)은 배터리 팩 내의 개별 셀들 간 전압, 충전 상태(SOC), 내부 저항 등의 불균형을 해소하여 전체 시스템의 성능과 수명을 향상시키기 위한 핵심 기술이다. 셀 밸런싱 회로는 크게 패시브 방식(passive balancing)과 액티브 방식(active balancing)으로 구분되며, 각각의 방식은 회로 구성, 동작 원리, 효율성, 비용 측면에서 상이한 특징을 지닌다.

1) 패시브 셀 밸런싱 회로

패시브 셀 밸런싱은 가장 단순하고 널리 사용되는 방식으로, 과충전된 셀의 에너지를 저항을 통해 소모함으로써 전압 균형을 맞추는 구조이다. 보통 각 셀의 양단에 바이패스 저항과 스위칭 소자(MOSFET 등)를 연결하여, 특정 임계 전압 이상이 되면 해당 셀에 연결된 저항 경로를 활성화하여 전류를 흐르게 한다. 이 방식은 구조가 간단하고 구현 비용이 낮으며, 외부 회로의 간섭이 적은 장점이 있다. 하지만 셀 에너지를 열로 소모하기 때문에 효율성이 낮고, 고속 충방전이 반복되는 환경에서는 전력 손실이 크다. 또한 발열에 대한 방열 설계가 필요하며, 셀 개수가 많아질수록 전체 에너지 손실이 누적된다.

패시브 방식은 보통 보조 FET나 릴레이와 함께 사용되며, 전압 감지 회로가 함께 포함되어야 한다. 상업용 BMS에서는 전압 감지 IC와 함께 10~20개의 셀을 통합 관리하는 모듈로 구성되기도 하며, 자동차용 BMS에서는 각 셀 모듈에서 전압/온도 측정 및 패시브 밸런싱 회로를 병렬로 운용하는 구조를 채택한다.

2) 액티브 셀 밸런싱 회로

액티브 방식은 전압이 높은 셀에서 낮은 셀로 직접 에너지를 이동시켜 균형을 맞추는 구조로, 에너지 손실을 최소화할 수 있는 고효율 방식이다. 다양한 토폴로지가 존재하며, 대표적으로 커패시터 기반, 인덕터 기반, 플라이백 변압기 기반, Cuk 컨버터 기반 방식 등이 있다.

2-1. 커패시터 셔틀 방식

커패시터 셔틀 방식은 하나의 커패시터가 셀 간을 오가며 에너지를 충방전 방식으로 전달하는 구조이다. 예를 들어, 셀1에서 커패시터를 충전한 후, 해당 커패시터를 셀2로 전환하여 방전함으로써 에너지를 이동시키는 방식이다. 각 셀 사이에 커패시터가 위치하고, 양쪽에는 MOSFET이 배치되어 스위칭 신호에 따라 경로가 형성된다. 회로가 비교적 간단하고, 소형 MCU로도 제어가 가능하다는 장점이 있으며, 회로 전체가 저전력으로 구동될 수 있다. 다만 커패시터 용량에 따라 전류 이동량이 제한되며, 다수의 셀 간 전환 논리가 복잡해질 수 있다.

2-2. 인덕터 기반 양방향 전류 이송 방식

인덕터를 이용한 방식은 두 셀 사이에 인덕터와 양방향 스위칭 회로를 구성하여, 한 셀에서 인덕터에 에너지를 저장한 후, 스위칭을 통해 다른 셀로 방전시키는 구조이다. 보통 하프브리지 형태로 N-MOSFET 두 개를 사용하며, PWM 신호를 통해 인덕터에 에너지를 충전하고 타이밍을 조절해 방전한다. 이 방식은 전류 용량이 크고 효율이 높으며, 에너지 손실이 적다는 장점이 있다. 하지만 인덕터의 자속 포화나 스위칭 노이즈, EMI 설계 등의 복잡성이 존재하며, 정확한 타이밍 제어가 요구된다.

2-3. 플라이백 트랜스포머 방식

플라이백 기반 밸런싱은 트랜스포머를 통해 다수의 셀 간 에너지를 공유할 수 있게 하는 방식이다. 트랜스포머 1차 측에 고전압 셀을 연결하여 에너지를 저장하고, 2차 측에서 낮은 전압 셀로 에너지를 전달한다. 이 방식은 다수의 셀 간 공유 구조를 만들 수 있어 확장성이 좋고, 중앙 제어기로 효율적인 밸런싱이 가능하다. 하지만 트랜스포머의 설계가 까다롭고, 절연, 누설 인덕턴스, 커플링 계수 등에 따라 시스템의 동작 안정성이 크게 좌우된다. 주로 고전력 ESS나 중대형 배터리 시스템에서 사용된다.

2-4. 양방향 Cuk 컨버터 기반 방식

Cuk 컨버터는 입력과 출력 모두 전류 연속 특성을 가지며, 전압 승강이 가능한 특성을 활용한 밸런싱 회로 구성에 사용된다. 각 셀 간에 Cuk 컨버터 모듈을 배치하고, 스위칭 제어를 통해 고전압 셀의 에너지를 다른 셀로 이동시킨다. 이 방식은 스위칭 손실이 낮고, 입출력 전류 리플이 적으며, 에너지 전달 효율이 매우 높다. 하지만 회로가 복잡하고 부품 수가 많으며, 제어 알고리즘 구현이 어렵다는 단점이 있다. 또한 Cuk 컨버터는 입력과 출력이 전기적으로 연결되어 있지 않아야 하므로, 절연 설계가 필수이다.

3) 하이브리드 셀 밸런싱 회로

최근에는 패시브와 액티브 방식의 장점을 결합한 하이브리드 셀 밸런싱 구조도 연구되고 있다. 예를 들어, 특정 수준 이상의 전압 차가 발생할 경우에는 액티브 방식으로 우선 조절하고, 미세한 불균형은 패시브 방식으로 지속 조정하는 형태이다. 이를 통해 회로 복잡

도는 일정 수준 이하로 유지하면서도 에너지 효율과 밸런싱 속도 모두를 확보할 수 있다. 일부 시스템에서는 고속 충방전 시에는 액티브 방식으로 대응하고, 정지 상태 또는 대기 중에는 패시브 회로를 유지함으로써 전체 시스템의 전력 최적화를 도모한다.

결론적으로 셀 밸런싱 회로의 선택은 시스템의 응용 분야, 셀 수, 전력 규모, 설계 복잡도, 비용 등에 따라 달라지며, 고성능 BMS일수록 액티브 또는 하이브리드 방식이 선호되는 추세이다.

본 연구에서 제안하는 커패시터 셔틀 방식은 하드웨어 구현이 비교적 단순하면서도 에너지 손실이 적고, 경량 AI 기반의 제어 알고리즘과 결합이 용이하다는 장점을 가진다. 이러한 특성 덕분에 소형 BMS 또는 엣지 AI 시스템과 같은 저전력·경량 환경에 특히 적합한 방식으로 평가된다.

전하 이동 메커니즘은 커패시터 셔틀 원리를 기반으로 한다. 4셀로 구성된 배터리 모듈 내에서 인접한 셀 사이에는 총 3개의 커패시터가 배치되어 있으며, 각 커패시터의 양단은 두 개의 N채널 MOSFET에 의해 제어된다. MCU의 GPIO 핀에서 출력되는 디지털 신호는 해당 MOSFET의 게이트에 전달되며, 이를 통해 스위칭 동작이 이루어진다.

예를 들어, AI 모델이 Cell1과 Cell2 사이의 전압 불균형을 감지한 경우, 커패시터 C1 양단의 MOSFET(M1, M2)이 동시에 활성화되어 고전압 셀(Cell1)로부터 커패시터에 에너지가 저장된다. 이후 M1과 M2는 OFF되고, M3와 M4가 ON 상태로 전환되면서 저장된 전하가 저전압 셀(Cell2)로 전달되어 전압 밸런싱이 수행된다.

이 방식은 회로 구조가 간단하고 제어 방식이 직관적이라는 이점을 가지며, 저전력 마이크로컨트롤러 환경에서도 안정적으로 작동할 수 있다. 또한, 커패시터를 통한 직접적인 에너지 이동은 저항을 이용한 패시브 셀 밸런싱 방식보다 에너지 효율이 뛰어나고 손실이 적다. 본 시스템은 경량 AI 모델의 추론 결과를 하드웨어 제어로 실시간 반영함으로써, 전체적인 응답 지연을 최소화하고 독립적이며 효율적인 BMS 운용이 가능하도록 한다. 전체 회로 구성은 <그림 4>에 제시되어 있다.

<그림 4> 커패시터 셔틀 방식 셀 밸런싱 회로도

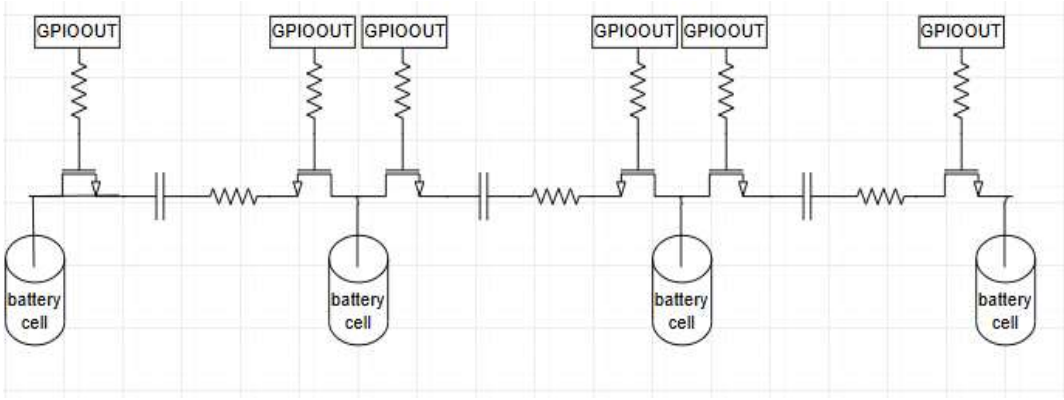

IV. 결 론

본 연구에서는 클라우드 기반 BMS의 의존도를 줄이고, 실시간 셀 제어가 가능한 경량 AI 기반 Edge-BMS 구현을 목표로, STM32 마이크로컨트롤러 상에서 구동 가능한 SoC 예측 모델을 설계하였다. 기존의 LSTM 및 GRU 기반 모델은 정확도는 우수하였으나, 모델 크기 및 연산 자원 요구로 인해 임베디드 디바이스에 적용하기에 어려움이 있었다. 이에 본 연구에서는 1D-CNN 기반의 특성 추출 후 MLP를 결합한 경량 구조를 채택하고, 전체 파라미터 수를 8만 개 이하로 제한했다. 모델 깊이를 최소화하는 구조 설계를 통해 연산량을 대폭 절감하여 STM32 환경에 직접 탑재가 가능하도록 하였다. 실험 결과, 제안된 모델은 전류, 전압, 온도 시계열 입력에 기반하여 SoC를 안정적으로 예측하였으며, 이후 셀 간 SoC 편차를 활용한 셀 밸런싱 제어 알고리즘에 적용 가능함을 확인하였다. 본 연구 결과는 향후 저전력 환경에서의 분산형 BMS 구현 및 실시간 배터리 상태 모니터링 기술 개발에 실질적인 기여를 할 수 있을 것으로 기대된다. 향후에는 SoH 예측 모델과의 통합 및 셀 불균형 보정 알고리즘의 고도화를 통해 더욱 정밀한 배터리 관리가 가능할 것으로 전망된다.

참고문헌

[1] Md. Khaja Farman and Jarabana Nikhila(2024), "AI-Enhanced Battery Management Systems for Electric Vehicles: Advancing Safety, Performance, and Longevity," E3S Web of Conferences, 591: 1~13, EDP Sciences.

[2] I. Marri and co-authors(2023), "Comparing Machine Learning Strategies for SoH Estimation of Lithium-Ion Batteries Using a Feature-Based Approach," Energies, 16(11): 1-19, MDPI.

[3] Arman Sheikhani and Ervin Agic(2024), "LITHIUM-ION BATTERY SOH FORECASTING WITH DEEP LEARNING AUGMENTED BY EXPLAINABLE MACHINE LEARNING," Thesis for the Degree of Master of Science in Engineering, Mälardalens University.

[4] Yancheng Song and Jiaqi Lu(2024), "SOC and SOH Prediction of Lithium-Ion Batteries Based on LSTM–AUKF Joint Algorithm," Energy Science & Engineering, 13: 240~254, John Wiley and Sons Ltd.

[5] Spyridon Giazitzis and Maciej Sakwa(2024), "A Case Study of a Tiny Machine Learning Application for Battery State-of-Charge Estimation," Electronics, 13(10): 1-17, MDPI.

[6] António Barros and Edoardo Peretti(2024), "Adaptive Extended Kalman Filtering for Battery State of Charge Estimation on STM32," IEEE Embedded Systems Letters, 17(3): 160~163, IEEE Xplore.

[7] Nandan, Rohan, and Avinash Sharma (2023), "Consensual Neural Network (CoNN) for Accurate State of Charge Estimation in Lithium-Ion Batteries," SSRN Electronic Journal, 5274838: 1–25, Elsevier.

[8] Chemali, Elie, Philip J. Kollmeyer, Mehdi B. Ahmed, and Andreas Emadi (2017), "Long Short-Term Memory Networks for Accurate State-of-Charge Estimation of Li-ion Batteries," IEEE Transactions on Industrial Electronics, 65(8): 6730–6739, IEEE Press.

[9] Adnan Ashraf, Basit Ali, Mothanna S. A. Al Sunjury, Pietro Tricoli (2025), "A Comprehensive Review of the Art of Cell Balancing Techniques and Trade-Offs in Battery Management Systems," Energies, 18(13), Article No. 3321. MDPI.